

Proyecto: Forecasting de demanda del consumo de Energía

Diplomado de especialización de
desarrollo de aplicaciones con Inteligencia Artificial



PONTIFICIA
UNIVERSIDAD
CATÓLICA
DEL PERÚ

Integrantes:

Frank Ygnacio Rosas
Fiorela Lizárraga
Ricardo Llanos
Yulian Cama

Definición del Problema

El desafío busca prever la demanda del consumo de energía en una planta dado un grupo de datos históricos sobre el consumo respectivo por las diversas áreas de trabajo.

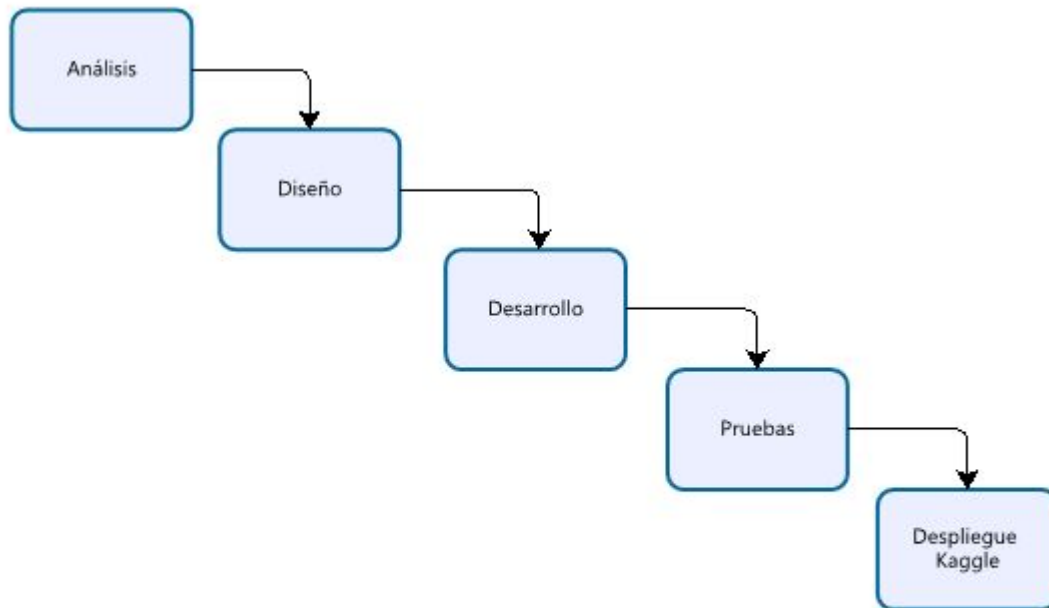
Objetivos

1. El objetivo principal es encontrar un modelo que nos permita predecir consumos de energía a futuro en la planta.
2. Reducir la incertidumbre respecto al gasto, mensual o anual que se pueda tener por el consumo.



Metodología a Usar


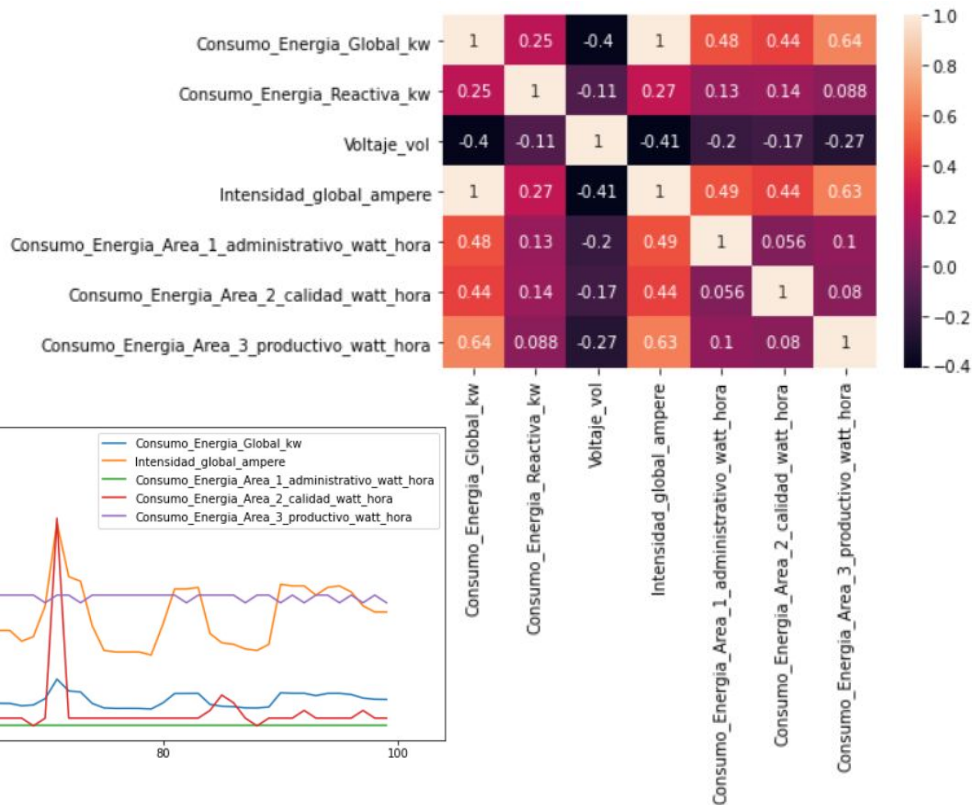
- Análisis (Entendimiento del problema)
- Diseño (Investigación de modelos a usar y propuestas)
- Desarrollo (Implementación)
- Pruebas (Validación del modelo elegido)
- Despliegue en Kaggle



1. Exploratory Data Analysis - Data Visualization


A continuación, se mencionan las variables de mayor correlación con la variable objetivo **Consumo_energia_global_kw**.

- Intensidad_global_ampere (1)
- Consumo_Energía_Area_1_administrativo_watt_hora (0.48)
- Consumo_Energia_Area_2_calidad_watt_hora (0.44)
- Consumo_Energia_Area_3_productivo_watt_hora (0.64)




1. Exploratory Data Analysis - Data Visualization

Observamos que la variable objetivo `Consumo_Energía_Global_kw` e `Intensidad_global_ampere` siguen una misma tendencia.



Con las variables escaladas confirmamos la relación entre ambas:



2. Feature Engineering

- Los valores del dataset fueron convertidos a tipo float32.
- Se utilizó MinMaxScaler, para el escalamiento de los datos a un rango de 0 a 1.
- La variable esencial utilizada para el proceso predictivo fue 'Intensidad_global_ampere'.
- Se empleará el proceso de transformación inversa para devolver los valores luego de la predicción.

	Consumo_Energia_Global_kw	Intensidad_global_ampere
0	0.374796	0.377593
1	0.478363	0.473029
2	0.479631	0.473029
3	0.480898	0.473029
4	0.325005	0.323651
...
1954514	0.045808	0.049793
1954515	0.045265	0.049793
1954516	0.045265	0.049793
1954517	0.045084	0.049793
1954518	0.044722	0.049793

1954519 rows x 2 columns

3. Modeling

Desarrollamos un modelo con una capa LSTM con 4 neuronas, seguida de una capa densa de salida que predecirá un valor.

Usamos la función de pérdida de error cuadrático medio, ya que el problema está evaluado con la métrica de error RMSE, y el optimizador “adam” como un método estándar.

Ajustamos el modelo a 200 épocas con un batch_size igual a 72 y con datos de validación separados de nuestro conjunto de datos inicial.

```
Model: "sequential"
```

Layer (type)	Output Shape	Param #
=====		
lstm (LSTM)	(None, 4)	96
dense (Dense)	(None, 1)	5
=====		

```
Total params: 101
```

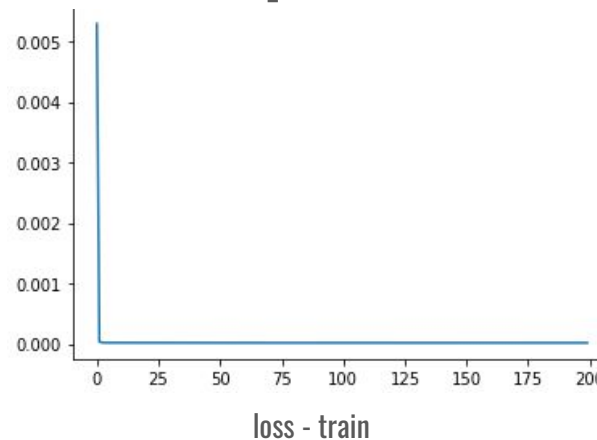
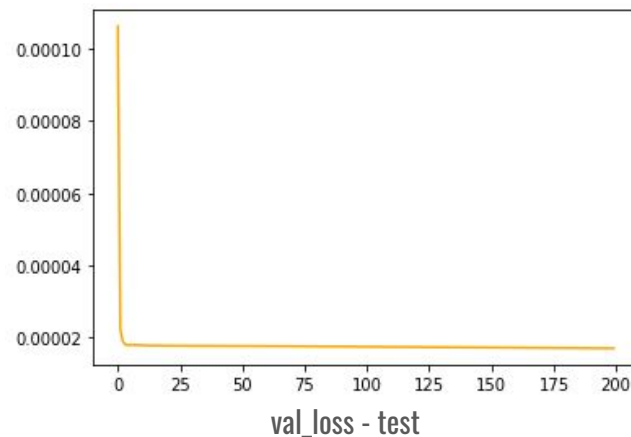
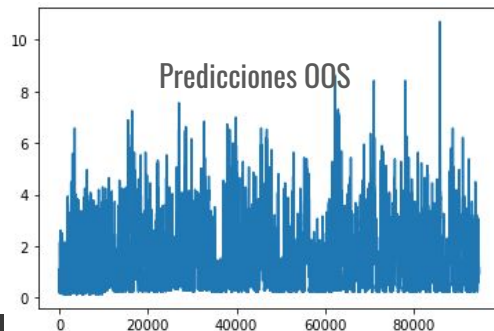
```
Trainable params: 101
```

```
Non-trainable params: 0
```

4. Resultados del Modelo

```
2 history = model1.fit(
3     train_X, train_y,
4     epochs=200, batch_size=72,
5     validation_data=(test_X, test_y),
6     verbose=2, shuffle=False
7 )
```

```
Epoch 192/200
1466/1466 - 4s - loss: 1.7167e-05 - val_loss: 1.6984e-05
Epoch 193/200
1466/1466 - 4s - loss: 1.7166e-05 - val_loss: 1.6981e-05
Epoch 194/200
1466/1466 - 4s - loss: 1.7165e-05 - val_loss: 1.6979e-05
Epoch 195/200
1466/1466 - 4s - loss: 1.7164e-05 - val_loss: 1.6977e-05
Epoch 196/200
1466/1466 - 4s - loss: 1.7163e-05 - val_loss: 1.6974e-05
Epoch 197/200
1466/1466 - 4s - loss: 1.7162e-05 - val_loss: 1.6972e-05
Epoch 198/200
1466/1466 - 4s - loss: 1.7161e-05 - val_loss: 1.6970e-05
Epoch 199/200
1466/1466 - 4s - loss: 1.7160e-05 - val_loss: 1.6968e-05
Epoch 200/200
1466/1466 - 4s - loss: 1.7159e-05 - val_loss: 1.6966e-05
```



Notas: Modelling, Feature Selection & Tuning

- El aprendizaje del modelo ha resultado conflictivo por algunos momentos, haciendo que el valor de pérdida en el set de validación se mantenga constante en breves iteraciones para posteriormente seguir cayendo. Esto quizá se deba a la simplicidad del modelo de aprendizaje neuronal propuesto.
- Un insight importante ha sido la capacidad de, a pesar de la condición anterior, poder encontrar un valor RMSE bastante bajo en el conjunto de prueba, siendo este de 0.004.






















```
[99] 1 # calculate RMSE
      2 rmse = sqrt(mean_squared_error(inv_y, inv_yhat))
      3 print('Test RMSE: %.3f' % rmse)

Test RMSE: 0.004
```

- En el reto Kaggle, los resultados también se mantuvieron positivos. Acaso una razón importante de esta capacidad de funcionar correctamente ($\text{RMSE} < 0.1$), sea indicativo de que el feature seleccionado es, en efecto, el óptimo para la solución de la problemática.

6. Resultados Predictivos - Reto Kaggle

RMSE OOS: 0.07593

#	Team Name	Notebook	Team Members	Score ?	Entries	Last
1	Alexis y sus Amigos		 	0.03064	8	5d
2	overfitting.com		   	0.03208	13	6h
3	Grupo_y'		  	0.03537	13	2d
4	Team 1		   	0.07593	21	19h
<p>Your Best Entry </p> <p>Your submission scored 0.08974, which is not an improvement of your best score. Keep trying!</p>						
5	Ceci, Abraham, Carlos, Edgar		   	0.16454	10	2d
6	GRUPO 5 (CEJW)		  	0.23938	1	3d

A	B
ID_Registro	Consumo_Energia_Global_kw
1975259	0.61574185
1975260	0.61574185
1975261	0.5667928
1975262	0.5179946
1975263	0.5179946
1975264	0.4208956
1975265	0.37261838
1975266	0.5667928
1975267	1.061298
1975268	1.061298
1975269	1.1111823
1975270	1.1111823
1975271	1.0114654
1975272	0.4208956
1975273	0.4208956
1975274	0.4208956
1975275	0.4208956
1975276	0.4208956
1975277	0.4208956
1975278	0.4208956
1975279	0.4208956
1975280	0.5179946
1975281	0.5179946
1975282	0.5179946
1975283	0.5179946
1975284	0.5179946
1975285	0.5179946
1975286	0.5179946
1975287	0.5179946
1975288	0.5179946
1975289	0.61574185
1975290	0.61574185


7. Estrategias de Negocio

1. Segmentación de la diversificación energética de las áreas de trabajo en relación al “momentum” de consumo energético.

Momentum : condición de aceleración/desaceleración del cambio de un valor en una serie temporal en relación a una ventana histórica [2].

Explicación : apertura/cierre de áreas de trabajo para consumo energético cuando exista una alta tasa de variación de dicho valor.

Representación gráfica:

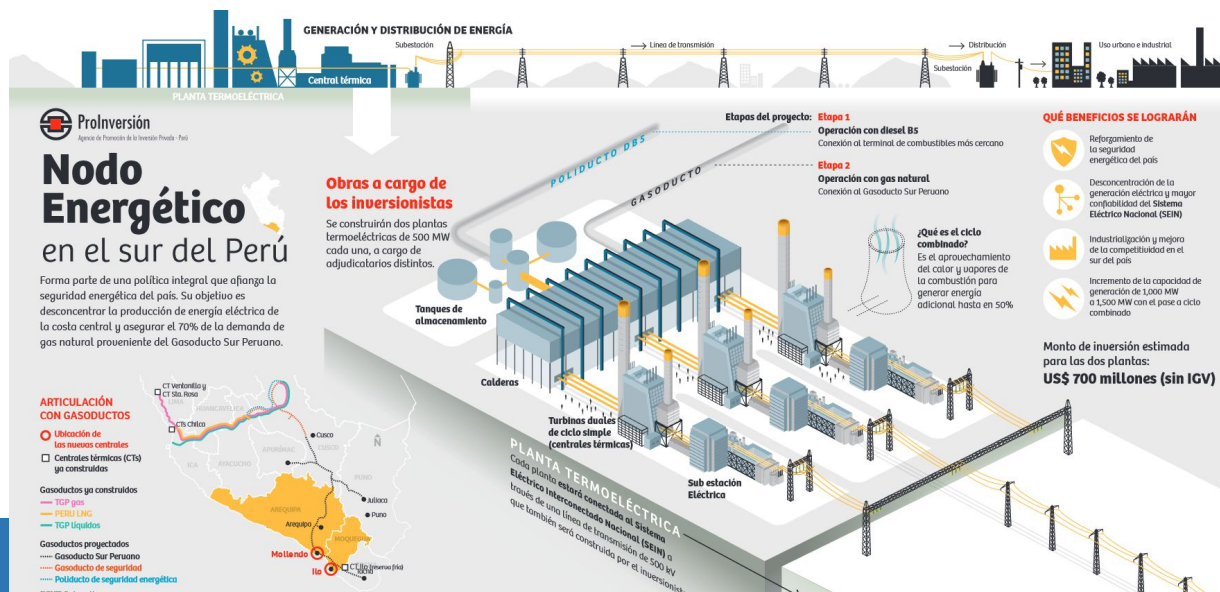


7. Estrategias de Negocio

2. Estructuración de nodos energéticos para descentralización del consumo energético

Un nodo energético permite poseer una diversificación vascular del consumo de energía en relación a los puntos desde donde esta se genera. Para ello, resulta necesario la aplicación de una estructura definida por expertos para la elaboración de este road-map físico de flujo de energía [3].

En el Perú, existe un caso conocido de la empresa Engie Energía S.A.A. denominado “Nodo Energético Perú”.



Conclusiones

- Dada la significativa relación entre la variable predictora `Intensidad_global_ampere` y la variable a predecir `Consumo_Energía_Global_kw`, ha podido conseguirse el objetivo de predicción a un nivel lo suficientemente certero ($RMSE < 0.1$) para validar la estructura neuronal básica planteada.
- Dada la estructura neuronal básica planteada, puede formularse mejoras a la misma para profundizar el proceso de aprendizaje y perfeccionar el valor de métrica obtenido OOS. Sin embargo, creemos que dicho proceso puede generar escenarios de baja flexibilidad del modelo a nuevos datos que no se encuentran registrados tanto IS como OOS, y que son propios de un entorno aplicativo del mundo real.
- Dada la problemática del presente caso de estudio en el mundo real, se sugiere en primera instancia la utilización de mayores variables útiles a la variable a predecir en lugar de complejizar la estructura neuronal de aprendizaje. Esto involucra un mayor acercamiento al mundo real de mayores condiciones de funcionamiento para una planta energética que la sola dependencia de un modelo neuronal profundo.

Bibliografía

- [1] DHIR, R., 2021. *Momentum*. [online] Investopedia. Available at: <<https://www.investopedia.com/terms/m/momentum.asp>> [Accessed 2 April 2021].
- [2] HUANG, LI, WANG & ZHOU. 2020. *Time Series momentum: Is it there?* Journal of Financial Economics. Available at: <<https://www.sciencedirect.com/science/article/abs/pii/S0304405X19301953>> [Accessed 2 April 2021].
- [3] Proinversion.gob.pe. 2017. *Plan Pro Inversion Engie Energias*. [online] Available at: <https://www.proinversion.gob.pe/RepositorioAPS/0/1/JER/SALA_PRENSA_INFOGRAFIAS/infogrfia%20nodo%20energetico.pdf> [Accessed 2 April 2021].
- [4] BROWNLEE, J., 2021. *Multivariate Time Series Forecasting with LSTMs in Keras*. [online] Machine Learning Mastery. Available at: <<https://machinelearningmastery.com/multivariate-time-series-forecasting-lstms-keras/>> [Accessed 2 April 2021].
- [5] BROWNLEE, J., 2021. *On the Suitability of Long Short-Term Memory Networks for Time Series Forecasting*. [online] Machine Learning Mastery. Available at: <<https://machinelearningmastery.com/suitability-long-short-term-memory-networks-time-series-forecasting/>> [Accessed 2 April 2021].
- [6] BROWNLEE, J., 2021. *Stacked Long Short-Term Memory Networks*. [online] Machine Learning Mastery. Available at: <<https://machinelearningmastery.com/stacked-long-short-term-memory-networks/>> [Accessed 2 April 2021].
- [7] BROWNLEE, J., 2021. *Use Early Stopping to Halt the Training of Neural Networks At the Right Time*. [online] Machine Learning Mastery. Available at: <<https://machinelearningmastery.com/how-to-stop-training-deep-neural-networks-at-the-right-time-using-early-stopping/>> [Accessed 2 April 2021].